

Previsão de Temperatura Utilizando Redes Neurais LSTM

Emanuel Rocha

1 Introdução

A previsão de séries temporais meteorológicas é um problema relevante em diversas áreas, como agricultura, planejamento urbano e gestão de recursos naturais. Neste trabalho, utiliza-se uma Rede Neural Recorrente com células LSTM (Long Short-Term Memory) para a previsão da temperatura máxima diária, com base em dados históricos reais fornecidos pelo Instituto Nacional de Meteorologia (INMET).

O objetivo é avaliar a capacidade preditiva do modelo ao realizar previsões de múltiplos passos à frente, utilizando informações históricas de temperatura e umidade relativa do ar.

2 Base de Dados

A base de dados contém registros diários de temperatura máxima e umidade relativa do ar coletados na cidade de Bambuí (MG), abrangendo o período de 2011 a 2016. Após a importação dos dados, foram removidas colunas irrelevantes e o índice temporal foi ajustado para a data de observação.

A divisão dos conjuntos seguiu estritamente o enunciado da atividade:

- Treinamento: janeiro/2011 a junho/2015;
- Validação: julho/2015 a dezembro/2015;
- Teste: janeiro/2016 a dezembro/2016.

3 Análise Exploratória e Pré-processamento

Inicialmente, realizou-se uma análise exploratória das séries temporais, avaliando o comportamento ao longo dos anos, a distribuição dos valores e a presença de outliers. Foram identificados poucos valores ausentes, os quais foram tratados por interpolação, garantindo a continuidade da série.

Os dados passaram por estabilização de variância (quando aplicável) e normalização utilizando o método Min-Max. Em seguida, foi aplicado o janelamento móvel com:

- Janela de entrada de 30 dias (temperatura e umidade);
- Janela de saída de 10 dias futuros de temperatura.

4 Arquitetura da Rede Neural

A arquitetura proposta é composta por uma rede neural recorrente profunda baseada em LSTM. A entrada do modelo possui dimensão (30×2) , representando 30 dias históricos de temperatura máxima e umidade relativa.

A rede é formada pelas seguintes camadas:

- Primeira camada LSTM com 16 unidades e retorno de dropout em sequência;
- Segunda camada LSTM com 32 unidades e retorno de dropout em sequência;
- Camada LSTM Bidirecional com 32 unidades em cada direção com retorno de dropout em sequência;
- Camada densa intermediária com 16 neurônios;
- Camada densa de saída com 10 neurônios, correspondente à previsão da temperatura máxima para os 10 dias subsequentes.

O modelo possui um total de 25.338 parâmetros treináveis.

x_train	input:	[(None, 30, 2)]
InputLayer	output:	[(None, 30, 2)]



lstm_3	input:	(None, 30, 2)
LSTM	output:	(None, 30, 16)



dropout_3	input:	(None, 30, 16)
Dropout	output:	(None, 30, 16)



lstm_4	input:	(None, 30, 16)
LSTM	output:	(None, 30, 32)



dropout_4	input:	(None, 30, 32)
Dropout	output:	(None, 30, 32)



bidirectional_1(lstm_5)	input:	(None, 30, 32)
Bidirectional(LSTM)	output:	(None, 64)



dropout_5	input:	(None, 64)
Dropout	output:	(None, 64)

5 Treinamento

O treinamento foi realizado utilizando o otimizador Adam e a função de custo Erro Quadrático Médio (MSE). Foi aplicado Early Stopping monitorando o erro de validação, visando evitar sobreajuste e garantir melhor generalização do modelo.

A convergência do treinamento foi avaliada por meio da comparação entre as curvas de erro dos conjuntos de treino e validação.

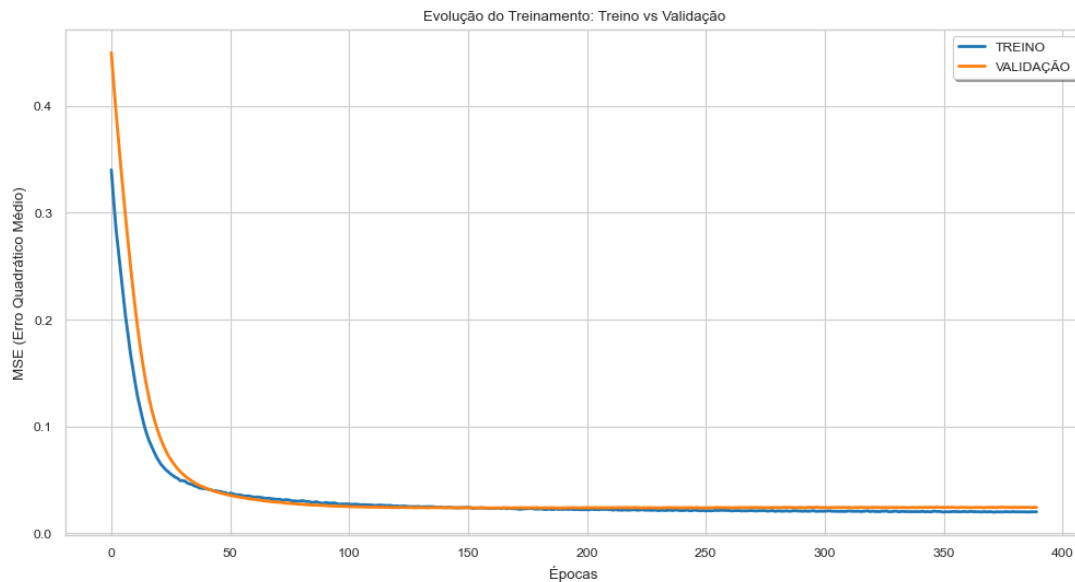


Figura 2: Curva de convergência do modelo durante o treinamento e validação.

6 Resultados e Avaliação

Após o treinamento, o modelo foi aplicado para prever a temperatura máxima ao longo de todo o ano de 2016. A avaliação foi realizada comparando os valores previstos com os valores reais do conjunto de teste.

As métricas obtidas foram:

- MAPE: 7,62%;
- R^2 : 0,1420;
- MSE: 7,8614;
- RMSE: 2,8038.

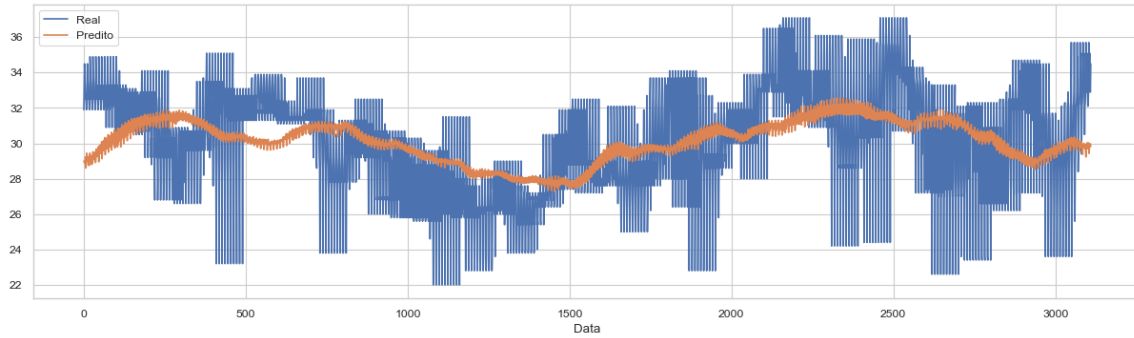


Figura 3: Comparação entre valores reais e preditos da temperatura máxima no ano de 2016.

Observa-se que o modelo apresenta erro médio relativamente baixo em termos absolutos, porém um coeficiente de determinação reduzido, indicando dificuldade em explicar completamente a variabilidade da série.

7 Discussão

A rede neural LSTM foi capaz de capturar padrões temporais gerais da série de temperatura, apresentando previsões coerentes ao longo do tempo. Entretanto, observou-se que a linha de predição tendia a se atrasar em relação à linha real, ou seja, os picos e vales de temperatura eram previstos com certo deslocamento temporal. Períodos com maior variabilidade térmica e eventos climáticos abruptos impactaram negativamente a qualidade da previsão.

O baixo valor de R^2 sugere que, embora o erro médio seja moderado, o modelo não consegue explicar grande parte da variância da série, o que é esperado em dados meteorológicos altamente dependentes de fatores externos não observados e da própria defasagem temporal do modelo.

8 Conclusão

Neste trabalho, foi desenvolvida uma rede neural LSTM para previsão de temperatura máxima diária, utilizando dados reais do INMET. Os resultados indicam que o modelo possui capacidade preditiva razoável, especialmente para capturar tendências gerais da série temporal.

Apesar das limitações observadas, a abordagem apresenta potencial de uso como ferramenta auxiliar em aplicações reais, sendo passível de melhorias com a inclusão de novas variáveis e ajustes na arquitetura do modelo.